大家好，我是 Guide！在 LLM 应用开发中，Prompt 写得再好，如果没有一个稳定靠谱的模型基座，输出结果依然像“开盲盒”。

很多小伙伴在项目起步时会纠结：到底是花钱买现成的 API 省心，还是自己折腾本地部署省钱？这篇文章就带大家做一次“穿透式”对比，拆解阿里云百炼 API 与 Ollama 本地部署这两大主流方案，帮你选出最适合你项目的方式。

云端 API vs 本地部署

在开始之前，先了解两种方案的特点，选择适合你的方式：

对比项	阿里云百炼 API (云端)	Ollama 本地部署 (本地)	点评
部署难度	**零部署**，开箱即用	需要安装、配置环境	想快速上线选云端，想折腾底层选本地。
硬件要求	**无要求**	极高（内存/显存是刚需）	本地跑 7B 模型至少得 16G 内存。
推理性能	极快（专业 GPU 集群）	取决于你的显卡	生产环境的吞吐量云端完胜。
费用成本	按 Token 计费（有免费额度）	**完全免费**	适合“白嫖”党做本地实验。
数据隐私	数据上传云端	**数据 100% 本地化**	金融、内网环境建议选本地。
适用场景	**生产环境、高质量业务**	开发测试、隐私敏感场景	**没有银弹**，看你的业务痛点在哪。

如果是为了更好的分析效果，且不想因为硬件性能导致系统“假死”，个人强烈建议首选**阿里云百炼 API**。本地模型虽然香，但对普通开发机来说，处理长文本分析简直是“折磨”。

下面，我会详细介绍这两种接入大模型的方式

方案一：阿里云百炼 API

平台简介

阿里云百炼是一站式大模型开发与应用平台，集成了通义千问及主流第三方模型。它为开发者提供了**兼容 OpenAI 的 API** 及全链路模型服务，这意味着你可以使用标准的 OpenAI SDK 来调用阿里云的模型。

核心优势：

- 开箱即用，无需自行部署或运维
- 直接调用通义千问（Qwen）全系列模型
- 支持 DeepSeek、GLM 等第三方大模型
- 提供可视化应用构建能力

模型选择

通义千问（Qwen）系列旗舰模型

模型	特点	适用场景	价格
qwen-max	效果最好，能力最强	复杂推理、多步骤任务	较高
qwen-plus	效果、速度、成本均衡	通用场景（推荐）	中等
qwen-turbo	高性价比、低延迟	简单任务、快速响应	较低
qwen-coder-plus	代码专用，工具调用强	代码生成与理解	中等

其他能力

- **多模态**：视觉理解、图像生成、视频生成、语音识别与合成
- **向量嵌入**：`text-embedding-v3`（推荐）、`text-embedding-v2`
- **细分领域**：长文本处理、翻译、法律、角色扮演等

模型进阶服务

- 模型调优：支持 SFT、CPT、DPO 等训练方法
- 模型部署：资源专享的推理服务
- 模型评测：人工评测、自动评测、基线评测

开通步骤

1. 注册阿里云账号

如果没有阿里云账号，先注册阿里云账号。

2. 开通阿里云百炼

使用**阿里云主账号**前往阿里云百炼大模型服务平台：

- 北京区域（推荐国内用户）
- 新加坡区域（海外用户）

阅读并同意协议后，将自动开通服务。如果未弹出服务协议，则表示已经开通。

> 如果提示"您尚未进行实名认证"，请先完成实名认证。

3. 获取 API Key

前往**密钥管理**页面：

- 北京区域密钥管理
- 新加坡区域密钥管理

点击**创建 API-KEY**，保存生成的密钥。

> **安全提示**：API Key 等同于账号密码，请妥善保管，不要泄露或提交到代码仓库。

4. 领取免费额度

新用户通常有免费试用额度，可在模型用量界面查看。

方案二：Ollama 本地部署

Ollama 简介

Ollama 是一个开源的本地大模型运行框架，让你可以在本地电脑上运行各种开源大模型。它提供了：

- **简单的命令行界面**：一行命令即可运行模型
- **OpenAI 兼容 API**：与云端 API 无缝切换
- **丰富的模型库**：支持 Llama、Qwen、Mistral、Gemma 等主流模型
- **跨平台支持**：macOS、Linux、Windows

安装 Ollama

macOS

使用命令下载：

```
# 使用 Homebrew 安装
brew install ollama
```

也可以直接访问 Ollama 下载页面 下载 macOS 安装包。

Linux

使用命令下载：

```
# 一键安装脚本
curl -fsSL https://ollama.com/install.sh | sh
```

也可以直接访问 Ollama 下载页面 下载 Linux 安装包。

Windows

访问 Ollama 下载页面 下载 Windows 安装包。

启动 Ollama 服务

命令行启动

如果你想直接看到运行日志，或者在排查问题，可以使用这个命令：

```
ollama serve
```

这个命令会启动 Ollama 的 API 服务（默认端口 11434）。执行该命令后，该终端窗口会被占用，**不要关闭它**。你需要打开**另一个**新的终端窗口来输入 `ollama run` 或 `ollama list` 等命令。

在 Linux 上，Ollama 通常作为系统服务安装。

```
# 启动服务
sudo systemctl start ollama
# 停止服务
sudo systemctl stop ollama
# 设置开机自启
sudo systemctl enable ollama
# 查看服务状态（检查是否运行成功）
sudo systemctl status ollama
```

图形化界面

对于 Windows 和 macOS 用户来说，也可以直接点击 Ollama 应用程序启动。

启动后，在任务栏右下角的系统托盘（Windows）/屏幕顶部的菜单栏（macOS）中会看到一个**羊驼图标**，这表示服务已在后台运行。

界面效果如下图所示：

通过可视化界面，你不需要在终端输入 `ollama run model`，直接点选即可聊天。并且，可以直观地看到哪些模型已下载。

所有的对话和模型运行都在你自己的电脑上完成，不会上传到云端。

验证安装

无论使用哪种方式启动，你都可以在浏览器中访问这个地址来验证：http://localhost:11434。

如果看到 **"Ollama is running"** 这行字，说明服务已经成功启动。

你也可以使用下面的命令验证：

```
ollama --version
# ollama version is 0.13.5
```

部署 Qwen 模型

拉取 Qwen 模型

Ollama 提供了多个版本的 Qwen 模型，我们这里以 Qwen2.5 为例进行介绍，根据你的硬件配置选择

模型	参数量	内存需求	适用场景
`qwen2.5:0.5b`	0.5B	~1GB	轻量级测试
`qwen2.5:1.5b`	1.5B	~2GB	开发测试
`qwen2.5:3b`	3B	~4GB	日常使用
`qwen2.5:7b`	7B	~8GB	推荐配置
`qwen2.5:14b`	14B	~16GB	高质量输出
`qwen2.5:32b`	32B	~32GB	最佳效果
`qwen2.5-coder:7b`	7B	~8GB	代码专用

除了可视化界面下载模型之外，也可以使用命令行拉取：

```
# 拉取模型（以 7B 为例）
ollama pull qwen2.5:7b

# 拉取代码专用模型
ollama pull qwen2.5-coder:7b

# 查看已下载的模型
ollama list
```

测试模型

除了可视化界面直接对话之外，也可以在命令行界面测试：

```
# 命令行对话测试
ollama run qwen2.5:7b

# 输入问题后按回车，输入 /bye 退出
>>> 你好，请介绍一下你自己
你好！我叫Qwen，是由阿里巴巴云开发的预训练语言模型。...
```

Ollama 常用命令

```
# 模型管理
ollama list              # 查看已安装模型
ollama pull <model>      # 下载模型
ollama rm <model>        # 删除模型
ollama show <model>      # 查看模型信息

# 运行模型
ollama run <model>       # 交互式对话
ollama run <model> "问题" # 单次问答

# 服务管理
ollama serve             # 启动服务
ollama ps                # 查看运行中的模型

# 创建自定义模型
ollama create <name> -f Modelfile  # 从 Modelfile 创建
```

自定义模型配置

可以通过 Modelfile 创建自定义配置的模型：

```
# Modelfile
FROM qwen2.5:7b

# 设置系统提示词
SYSTEM """
你是一个专业的 Java 面试官，擅长考察候选人的技术能力。
请用简洁专业的语言进行面试。
"""

# 调整参数
PARAMETER temperature 0.7
PARAMETER top_p 0.9
PARAMETER num_ctx 4096
```

```
# 创建自定义模型
ollama create interview-assistant -f Modelfile

# 使用自定义模型
ollama run interview-assistant
```

项目中使用本地模型

如果想要在项目中使用本地模型，可以这样修改 `application.yml`：

```yaml
spring:
  ai:
    openai:
      base-url: http://localhost:11434   # 不要加 /v1
      api-key: ollama
      chat:
        options:
          model: qwen2.5:7b
          temperature: 0.7
```

不过，不太建议这样做。我在自己的 20 款 Mac Pro 机器上实测简历分析耗时 10分多钟。

总结

本文主要介绍了接入大模型的两种主流方案：**阿里云百炼 API**（云端方案）与 **Ollama**（本地方案），并提供了详细的对比与操作指南。

方案对比与选择：

- **阿里云百炼 API**：适合**生产环境**。优势在于零部署、高性能 GPU 集群、模型质量最强（Qwen 全系列及第三方模型），按 Token 计费。
- **Ollama 本地部署**：适合**开发测试及隐私敏感场景**。优势在于完全免费、数据不出本地、无网络延迟，但受限于个人电脑硬件性能。

阿里云百炼接入流程：

- **模型丰富**：涵盖通义千问（qwen-max/plus/turbo）旗舰模型及多模态、向量嵌入等进阶服务。
- **开通便捷**：通过阿里云账号实名认证后，在百炼控制台创建 **API-KEY** 即可使用。其 API **兼容 OpenAI 标准**，方便开发者快速集成。

Ollama 本地部署指南：

- **跨平台支持**：支持 macOS、Linux 和 Windows，安装简单。
- **模型管理**：通过命令行（如 `ollama pull qwen2.5:7b`）或图形化界面快速部署 Qwen 系列开源模型。
- **灵活定制**：支持通过 `Modelfile` 自定义系统提示词（System Prompt）和推理参数（如 Temperature）。

实践建议：

- 对于高质量需求和复杂推理任务，**首推阿里云百炼 API。**
- 本地模型（如 Qwen2.5-7B）在普通硬件上处理长文本或复杂分析（如简历分析）时耗时较长（实测可能达 10 分钟以上），需根据硬件配置合理选择模型参数量。
- 在 Spring Boot 等项目中，两者均可通过修改 `base-url` 和 `api-key` 实现无缝切换。