大家好，我是 Guide。Spring AI 是 Spring 官方打造的 AI 应用开发框架，旨在将 AI 能力无缝集成到 Spring 生态系统中。它提供统一的、与具体模型无关的 API，让 Java开发者可以轻松实现**大模型调用、RAG（检索增强生成）、结构化输出以及流式响应**等核心功能。

本篇内容覆盖了 **Spring AI 基础、ChatClient 模型调用、Prompt 工程与模板、向量存储与 Embedding、流式响应与 SSE、异步处理、异常处理、配置与调优** 等核心模块，每道题都配有深度解析并结合项目实战代码。无论你是准备面试，还是想系统学习 Spring AI 技术，这篇文章都能帮到你。

需要注意，本篇内容主要是针对《SpringAI 智能面试平台+RAG知识库》用到的技术总结相关的面试题，后续会持续补充完善！

Spring AI 基础

什么是 Spring AI?

Spring AI 是 Spring 官方打造的 AI 应用开发框架，旨在将 AI 能力无缝集成到 Spring 生态系统中。它侧重于提供构建 AI 应用所需的**底层原子能力抽象**，让 Java 开发者可以像使用其他 Spring 组件一样，轻松地与大语言模型进行交互。

能力	说明	本项目应用场景
模型通信 (ChatClient)	统一接口与不同 LLM（OpenAI、Ollama、通义千问等）对话	简历评分、面试评估、知识库问答
提示词 (Prompt)	结构化管理发送给模型的提示词	使用 `.st` 模板文件管理提示词
RAG (检索增强生成)	通过 `vectorStore` 实现 RAG 模式	知识库向量化存储与语义检索
工具调用 (Function Calling)	模型调用 Java 应用中定义的方法	-
记忆 (ChatMemory)	管理多轮对话的上下文历史	RAG 聊天会话管理

> **注意**：Spring AI 本身未提供多智能体（Multi-agent）开发能力。若需在 Spring AI 项目中开发多智能体应用，可以考虑集成 **LangGraph4j**（Java 版 LangGraph）。

☆为什么选择 Spring AI?

如果你的项目基于 Spring Boot 技术栈，并且希望获得官方的长期支持、紧跟 Spring 生态发展步伐，那么可以优先考虑 Spring AI。

核心优势：

优势	说明
无缝集成	与现有 Spring Boot 技术栈完美融合，学习成本低，能快速上手
高度抽象	提供统一的、与具体模型无关的 API，轻松在 OpenAI、Ollama、通义千问之间切换
生态整合	整合向量数据库（Chroma, PGVector）、ETL 框架等 AI 应用开发所需的整个工具链

目前，Java 依然是企业级开发的主流，市面上有多款 AI 应用开发框架：

框架	特点	JDK 基线	框架绑定	适用场景
Spring AI	Spring 官方，原生集成	**JDK 17+**（建议 JDK 21）	**Spring Boot 3.2+**（本项目使用 4.0.1）	Spring 项目首选，未来主流
LangChain4j	功能全面，更新快	JDK 8+	无限制（Boot 2.x/3.x）	老项目，兼容性需求
Solon-AI	轻量化，性能优秀	JDK 8+	Solon 生态（也支持 Boot）	Serverless、GraalVM 原生镜像
Agent-Flex	专注于 Agent 编排	JDK 11/17+	无框架依赖	Agent 编排需求为主

Spring AI 的杀手锏：它是 Spring 生态的"原生延伸"。将 AI 能力抽象成了标准组件，就像我们熟悉的 `JdbcTemplate` 或 `RestTemplate` 一样。对于老 Spring 玩家来说，接入成本几乎为零。

技术要为业务服务，不要为了炫技而引入复杂性。绝大多数商业场景不需要你突破算法，而是要解决这四个痛点：**大模型调用、RAG（检索增强生成）、结构化输出以及流式响应。**

Spring AI 2.0 在这些领域已经扎得足够深：

- **RAG 自动化**：对向量数据库（Redis, Milvus, pgvector）的抽象极其优雅，真正实现了"代码解耦"。同时支持 **Query Rewrite（改写）** 与 **前置过滤（Pre-filtering）**，显著提升召回精度。
- **性能榨取**：全面拥抱 **Java 21 虚拟线程（Virtual Threads）**，在处理高并发、长连接的 SSE AI 请求时，资源消耗极低，吞吐量提升明显。
- **工程规范**：配合 Spring Boot 4.0 和统一封装的 **StructuredOutputInvoker**，让 AI 模块的重试与结构化解析具备生产级鲁棒性。

Python在 AI 领域更强大，考虑过吗？

这是一个很好的问题。确实，Python 在 AI/ML 领域有更成熟的生态（PyTorch、LangChain、HuggingFace 等）。但选择 Java + Spring AI 有其合理性：

1. 应用场景不同

- **Python 擅长**：模型训练、算法研究、数据科学、快速原型验证
- **Java 擅长**：企业级应用开发、高并发服务、复杂业务逻辑

本项目是一个 **AI 应用** 而非 **AI 模型**，核心是调用大模型 API 而非训练模型。在这个场景下，Java 的工程化能力、类型安全、成熟的企业级生态反而是优势。

2. 团队技术栈

如果团队主要是 Java 开发者，强行引入 Python 会带来：

- 技术栈分裂，增加维护成本
- 需要处理 Java 和 Python 服务间的通信
- 部署复杂度上升

3. 性能与稳定性

Java 在长时间运行的服务中通常表现更稳定，JVM 的垃圾回收、JIT 编译在高并发场景下经过了充分验证。

4. Spring AI 已经足够

对于 **调用大模型 API、构建 RAG 应用、Embedding 向量化** 这些需求，Spring AI 的能力已经完全够用。我们不需要 Python 生态中那些用于模型训练的库。

5. 架构预留了扩展性

本项目通过 **Redis Stream 解耦了 AI 任务处理**，这是一个关键的架构决策：

```
┌──────────────────┐      Redis Stream      ┌──────────────────┐
│  Java 主服务     │ ─── 发送任务 ───→   │   消费者服务     │
│  (Spring Boot)   │                        │  (Java/Python)   │
└──────────────────┘      ←── 结果回写 ──  └──────────────────┘
```

- **当前阶段**：消费者用 Java 实现，与主服务技术栈统一，开发效率高
- **未来扩展**：如果需要更复杂的 AI 能力（如本地模型推理、自定义 Embedding、Agent 编排），可以用 **Python 实现新的消费者**，无缝接入现有架构

这种设计的好处：

- 主服务保持稳定，不受 AI 模块影响
- AI 模块可以独立迭代、独立扩缩容
- 技术选型灵活，哪个语言适合就用哪个

结论：技术选型应该根据具体场景和团队情况决定，而不是盲目追求"更强大"的技术。同时，好的架构设计应该为未来的变化预留空间。

ChatClient 与模型调用

☆ Spring AI 中如何调用大模型?

`ChatClient` 是 Spring AI 提供的流式 API，用于与大语言模型进行对话。本项目在三个核心场景中使用 ChatClient：

1. **简历评分**：`ResumeGradingService` - 分析简历内容并给出评分和建议
2. **面试评估**：`AnswerEvaluationService` - 评估面试回答并生成报告
3. **RAG 问答**：`KnowledgeBaseQueryService` - 基于知识库回答用户问题

基本调用模式：

```java
@Service
public class InterviewQuestionService {

    private final ChatClient chatClient;

    // 通过 ChatClient.Builder 构建（推荐方式）
    public InterviewQuestionService(ChatClient.Builder chatClientBuilder) {
        this.chatClient = chatClientBuilder.build();
    }

    public String generateQuestion(String resume) {
        return chatClient.prompt()
            .system("你是一位资深面试官...")  // 系统提示词
            .user(resume)                      // 用户输入
            .call()                            // 同步调用
            .content();                        // 获取文本内容
    }
```

```
}
```

结构化输出（映射为 Java 对象）：

本项目中，我们需要让 AI 返回结构化的面试问题列表，而不是纯文本。Spring AI 的 `BeanOutputConverter` 可以自动处理：

```java
// 定义响应结构
private record QuestionListDTO(List<QuestionDTO> questions) {}
private record QuestionDTO(String question, String type, String category) {}

// 使用 BeanOutputConverter
private final BeanOutputConverter<QuestionListDTO> outputConverter =
    new BeanOutputConverter<>(QuestionListDTO.class);

public List<QuestionDTO> generateQuestions(String resume) {
    // 将格式指令追加到系统提示词
    String systemPromptWithFormat = systemPrompt + "\n\n" +
outputConverter.getFormat();

    QuestionListDTO dto = chatClient.prompt()
        .system(systemPromptWithFormat)
        .user(userPrompt)
        .call()
        .entity(outputConverter);  // 自动解析 JSON 为 Java 对象

    return dto.questions();
}
```

`outputConverter.getFormat()` 会生成类似这样的指令：

```
Your response should be in JSON format.
The data structure for the JSON should match this Java class: ...
```

☆ Spring AI 中如何确保结构化解析的稳定性？

直接调用 `ChatClient` 解析 JSON 有时会因为网络波动或模型输出微小偏差导致失败。我通过封装 `StructuredOutputInvoker` 实现了生产级的稳定性：

1. **自动重试机制**：针对 `BeanOutputConverter` 的解析异常进行业务级重试。
2. **错误反馈闭环**：重试时将上次解析失败的 Error 注入到新提示词中，引导模型自我纠错。
3. **参数动态调优**：对解析失败的请求自动下调 `Temperature`，增强输出的确定性。

☆ ChatClient.Builder 和 ChatClient 有什么区别？

这是 Spring AI 中一个常见的困惑点：

ChatClient.Builder：

- 由 Spring AI 自动配置并注入
- 每次调用 `build()` 会创建新的 `ChatClient` 实例
- 可以在 `build()` 前进行定制化配置

ChatClient：

- 实际执行 API 调用的对象

- 通常在 Service 构造器中通过 `Builder.build()` 创建并复用

为什么不直接注入 ChatClient?

Spring AI 的设计理念是让开发者可以在构建时进行定制。例如添加默认的系统提示词、配置拦截器等:

```
public MyService(ChatClient.Builder builder) {
    this.chatClient = builder
        .defaultSystem("你是一个专业的助手")  // 全局默认系统提示词
        .build();
}
```

本项目中，我们直接使用默认配置:

```
// InterviewQuestionService.java:57-61
public InterviewQuestionService(
        ChatClient.Builder chatClientBuilder,
        @Value("classpath:prompts/interview-question-system.st") Resource
systemPromptResource,
        @Value("classpath:prompts/interview-question-user.st") Resource
userPromptResource) {
    this.chatClient = chatClientBuilder.build();
    // ...
}
```

call() 和 stream() 的区别是什么?

`call()` - 同步阻塞调用:

- 等待 AI 完整生成响应后一次性返回
- 适用于对延迟不敏感的后台任务（如**面试评分、分批评估**）

`stream()` - 流式响应:

- 返回 `Flux<String>`，AI 生成一个 token 就推送一个
- 适用于需要实时展示的场景（如聊天界面）

本项目的流式优化（探测窗口算法）：
在 RAG 问答场景下，为了防止 AI 在未检索到信息时输出长篇拒答，我实现了一个 **探测窗口 (Probe Window)**。系统会先缓冲前 120 个字符，若识别为拒答话术则直接截断并返回统一模板；若为有效回答则立刻放流，兼顾了体验与稳定性。

本项目的 RAG 知识库问答同时支持两种模式:

```
// KnowledgeBaseQueryService.java

// 同步调用（用于后台处理）- 第71-110行
public String answerQuestion(List<Long> knowledgeBaseIds, String question) {
    // 1. 验证知识库是否存在并更新问题计数
    countService.updateQuestionCounts(knowledgeBaseIds);

    // 2. 使用向量搜索检索相关文档（RAG）
    List<Document> relevantDocs = vectorService.similaritySearch(question,
knowledgeBaseIds, 5);

    // 3. 构建上下文
```

```java
    String context = relevantDocs.stream()
        .map(Document::getText)
        .collect(Collectors.joining("\n\n---\n\n"));

    // 4. 构建提示词
    String systemPrompt = buildSystemPrompt();
    String userPrompt = buildUserPrompt(context, question, knowledgeBaseIds);

    // 5. 调用AI生成回答
    String answer = chatClient.prompt()
        .system(systemPrompt)
        .user(userPrompt)
        .call()
        .content();

    return answer;
}

// 流式调用（用于前端实时展示）- 第152-197行
public Flux<String> answerQuestionStream(List<Long> knowledgeBaseIds, String
question) {
    // 1-3. 同上（检索相关文档、构建上下文和提示词）
    // ...

    // 4. 流式调用AI生成回答
    Flux<String> responseFlux = chatClient.prompt()
        .system(systemPrompt)
        .user(userPrompt)
        .stream()
        .content();

    return responseFlux
        .doOnComplete(() -> log.info("流式输出完成: kbIds={}", knowledgeBaseIds))
        .onErrorResume(e -> {
            log.error("流式输出失败: kbIds={}, error={}", knowledgeBaseIds,
e.getMessage(), e);
            return Flux.just("【错误】知识库查询失败: AI服务暂时不可用");
        });
}
```

Prompt 工程与模板

☆ 如何管理和组织 Prompt?

在实际项目中，Prompt 可能会很长且需要频繁调整。直接硬编码在 Java 代码中会导致：

- 代码可读性差
- 修改 Prompt 需要重新编译
- 难以进行版本管理

本项目的做法：Prompt 模板文件化

将 Prompt 存储在 `resources/prompts/` 目录下，使用 `.st` （StringTemplate）格式：

```
resources/
└── prompts/
    ├── interview-question-system.st   # 面试问题生成-系统提示词
    ├── interview-question-user.st     # 面试问题生成-用户提示词
    ├── interview-evaluation-system.st # 答案评估-系统提示词
    ├── resume-analysis-system.st      # 简历分析-系统提示词
    └── knowledgebase-query-system.st  # 知识库问答-系统提示词
```

加载与使用：

```java
@Service
public class InterviewQuestionService {

    private final PromptTemplate systemPromptTemplate;
    private final PromptTemplate userPromptTemplate;

    public InterviewQuestionService(
            ChatClient.Builder chatClientBuilder,
            @Value("classpath:prompts/interview-question-system.st") Resource
systemPromptResource,
            @Value("classpath:prompts/interview-question-user.st") Resource
userPromptResource) throws IOException {

        // 加载模板文件
        this.systemPromptTemplate = new PromptTemplate(
            systemPromptResource.getContentAsString(StandardCharsets.UTF_8)
        );
        this.userPromptTemplate = new PromptTemplate(
            userPromptResource.getContentAsString(StandardCharsets.UTF_8)
        );
    }

    public List<InterviewQuestionDTO> generateQuestions(String resumeText, int
questionCount) {
        // 渲染系统提示词（无变量）
        String systemPrompt = systemPromptTemplate.render();

        // 渲染用户提示词（带变量）
        Map<String, Object> variables = new HashMap<>();
        variables.put("questionCount", questionCount);
        variables.put("resumeText", resumeText);
        String userPrompt = userPromptTemplate.render(variables);

        // 调用 AI
        return chatClient.prompt()
            .system(systemPrompt)
            .user(userPrompt)
            .call()
            .entity(outputConverter);
    }
}
```

模板文件示例（interview-question-system.st）：

```
# Role
你是一位拥有 10 年以上经验的资深 Java 后端技术专家及大厂面试官。
```

```
# Task
请根据候选人简历生成针对性的面试问题集。

# Question Types
| 类型 | 说明 |
|------|------|
| PROJECT | 项目经历 |
| MYSQL | 数据库 |
| REDIS | 缓存 |
...

# Output Format
请直接输出一个 JSON 对象，不要包含 Markdown 代码块标签。
```

Prompt 设计有哪些最佳实践?

1. 角色设定（Role）

明确 AI 应该扮演的角色，这会显著影响输出质量：

```
你是一位拥有 10 年以上经验的资深 Java 后端技术专家及大厂（如阿里、腾讯、字节）面试官。
```

2. 任务描述（Task）

清晰说明需要完成什么任务：

```
请根据用户提供的【候选人简历内容】，生成一套针对性的面试问题集。
```

3. 约束条件（Constraints）

明确限制条件，避免 AI "跑偏"：

```
- 问题必须与简历内容高度相关，严禁出现简历未涉及的技术栈
- type 字段仅限 8 种枚举值
- 每道题目必须具有区分度
```

4. 输出格式（Output Format）

精确指定输出格式，特别是需要结构化输出时：

```
请直接输出一个 JSON 对象，不要包含 Markdown 代码块标签（如 ```json ）。
JSON 结构必须严格包含以下字段：
- questions: 对象数组，每个对象包含：
  - question: 字符串，面试问题内容
  - type: 字符串，问题类型
  - category: 字符串，细分类别
```

5. 示例驱动（Few-shot）

提供示例可以让 AI 更好地理解期望的输出：

```
示例输出：
{
  "questions": [
    {
      "question": "请介绍你项目中的分布式锁实现方案",
      "type": "PROJECT",
      "category": "分布式"
    }
  ]
}
```

向量存储与 Embedding

☆ Spring AI 如何集成向量数据库?

Spring AI 的 `VectorStore` 抽象层让我们可以轻松实现 RAG（检索增强生成）功能。本项目使用 PostgreSQL + pgvector 作为向量数据库。

这部分的详细介绍可以查看这篇文章：Spring AI + pgvector 实现 RAG 知识库问答。

依赖配置（build.gradle）：

```
// Spring AI 2.0 - PostgreSQL Vector Store (pgvector)
implementation "org.springframework.ai:spring-ai-starter-vector-store-pgvector:${springAiVersion}"
```

应用配置（application.yml）：

```yaml
spring:
  ai:
    vectorstore:
      pgvector:
        index-type: HNSW                # 索引算法
        distance-type: COSINE_DISTANCE  # 距离度量
        dimensions: 1024                # 向量维度
        initialize-schema: true         # 自动建表
        remove-existing-vector-store-table: false  # 保留现有表和数据
```

使用方式：

采用基于 Token 的切分策略（TokenTextSplitter）。相比字符切分，Token 切分更能贴合大模型的上下文窗口限制，并设置重叠区（Overlap）以防止语义在切分处断裂。

针对阿里云 DashScope 等主流 Embedding 接口的并发与批量限制（如单次最多 10 条），实现了分批入库逻辑，避免触发 API 报错并提升入库稳定性。

在向量化阶段将业务标识（如 `kb_id`）注入文档 Metadata，为后续的多租户隔离和快速过滤奠定基础。

```java
@Slf4j
@Service
public class KnowledgeBaseVectorService {

    /**
     * 阿里云 DashScope Embedding API 批量大小限制
```

```java
     */
    private static final int MAX_BATCH_SIZE = 10;

    private final VectorStore vectorStore;
    private final TextSplitter textSplitter;

    public KnowledgeBaseVectorService(VectorStore vectorStore, VectorRepository
vectorRepository) {
        this.vectorStore = vectorStore;
        this.vectorRepository = vectorRepository;
        // 使用 TokenTextSplitter，每个 chunk 约 500 tokens，重叠 50 tokens
        this.textSplitter = new TokenTextSplitter();
    }

    /**
     * 将知识库内容向量化并存储
     */
    @Transactional
    public void vectorizeAndStore(Long knowledgeBaseId, String content) {
        // 1. 删除该知识库的旧向量数据（支持重新向量化）
        deleteByKnowledgeBaseId(knowledgeBaseId);

        // 2. 文本分块：按 token 切分，每块约 500 tokens
        List<Document> chunks = textSplitter.apply(List.of(new
Document(content)));

        // 3. 添加元数据：标记每个 chunk 属于哪个知识库
        chunks.forEach(chunk -> chunk.getMetadata().put("kb_id",
knowledgeBaseId.toString()));

        // 4. 分批向量化并存储
        // 阿里云 DashScope API 限制 batch size <= 10，需要分批处理
        int totalChunks = chunks.size();
        int batchCount = (totalChunks + MAX_BATCH_SIZE - 1) / MAX_BATCH_SIZE;

        for (int i = 0; i < batchCount; i++) {
            int start = i * MAX_BATCH_SIZE;
            int end = Math.min(start + MAX_BATCH_SIZE, totalChunks);
            List<Document> batch = chunks.subList(start, end);
            vectorStore.add(batch);  // 调用 Embedding API 并存储到 pgvector
        }

        log.info("知识库向量化完成: kbId={}, chunks={}, batches={}",
                knowledgeBaseId, totalChunks, batchCount);
    }
}
```

代码说明：

- **分块策略**：使用 `TokenTextSplitter` 按 token 切分，每块约 500 tokens，重叠 50 tokens 保证上下文连贯性。
- **元数据标注**：为每个 chunk 添加 `kb_id` 元数据，支持按知识库过滤检索。
- **批次控制**：阿里云 DashScope Embedding API 限制每次最多 10 个文本，需要分批处理。
- **事务支持**：使用 `@Transactional` 确保向量删除和添加的原子性。

向量相似度搜索如何实现？

在实现多知识库的相似度搜索时，我采用了 **语义检索 + 内存过滤** 的混合方案。其核心逻辑是：首先利用向量数据库进行高维向量的近似最近邻搜索（ANN），然后结合业务维度的元数据进行精确过滤，最后进行结果截取。

核心实现流程：

1. **语义检索层**：利用 `VectorStore` 将用户查询实时向量化，并在底层数据库（如 pgvector）中通过 HNSW 算法检索语义最接近的文档片段。
2. **业务过滤层**：针对多知识库场景，在获取向量搜索结果后，通过 Stream 流对文档元数据（Metadata）中的 `kb_id` 进行匹配校验，确保数据隔离性。
3. **结果归并层**：根据配置的 `topK` 值对过滤后的结果进行截取，确保返回最相关且数量受控的上下文。

```java
/**
 * 基于多个知识库进行相似度搜索
 */
public List<Document> similaritySearch(String query, List<Long>
knowledgeBaseIds, int topK) {
    // 1. 向量相似度检索：使用 Spring AI 的 VectorStore 进行语义检索
    List<Document> allResults = vectorStore.similaritySearch(query);

    // 2. 元数据过滤：如果指定了知识库ID，只保留匹配的结果
    if (knowledgeBaseIds != null && !knowledgeBaseIds.isEmpty()) {
        allResults = allResults.stream()
            .filter(doc -> {
                Object kbId = doc.getMetadata().get("kb_id");
                if (kbId == null) return false;
                try {
                    Long kbIdLong = kbId instanceof Long
                        ? (Long) kbId
                        : Long.parseLong(kbId.toString());
                    return knowledgeBaseIds.contains(kbIdLong);
                } catch (NumberFormatException e) {
                    return false;
                }
            })
            .collect(Collectors.toList());
    }

    // 3. Top-K 截取：限制返回数量
    return allResults.stream()
        .limit(topK)
        .collect(Collectors.toList());
}
```

代码说明：

- **语义检索**：`VectorStore.similaritySearch()` 自动将 query 向量化并在 pgvector 中进行 HNSW 相似度检索。
- **元数据过滤**：支持按知识库 ID 过滤，实现多知识库联合检索或单独检索。
- **类型兼容**：兼容 `Long` 和 `String` 类型的 `kb_id`，确保向后兼容。
- **Top-K 返回**：限制返回数量，避免返回过多无关结果。

流程图：

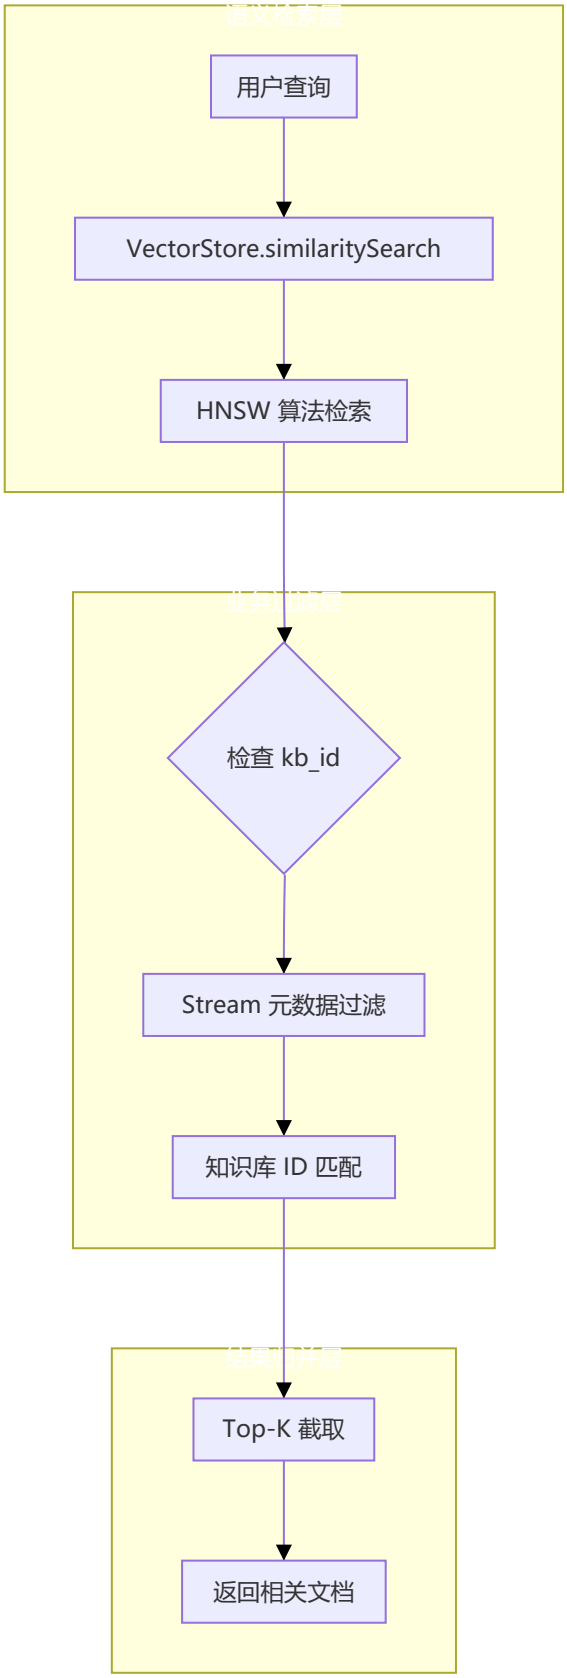

☆ 为什么需要分批处理 Embedding?

这是本项目在知识库向量化过程中的一个核心工程优化。

问题背景:

阿里云 DashScope 的 Embedding 接口对单次请求的文本数量有严格限制（最多 10 条）。而一份知识库文档经过 `TokenTextSplitter` 切分后，通常会产生几十甚至上百个文本块。如果一次性发送，会导致请求失败。

解决方案（`KnowledgeBaseVectorService.java`）：

```
private static final int MAX_BATCH_SIZE = 10;

public void vectorizeAndStore(Long knowledgeBaseId, String content) {
    // 1. 文本分块
    List<Document> chunks = textSplitter.apply(List.of(new Document(content)));

    // 2. 计算批次数（向上取整）
    int totalChunks = chunks.size();
    int batchCount = (totalChunks + MAX_BATCH_SIZE - 1) / MAX_BATCH_SIZE;

    // 3. 分批调用 vectorStore.add()
    for (int i = 0; i < batchCount; i++) {
        int start = i * MAX_BATCH_SIZE;
        int end = Math.min(start + MAX_BATCH_SIZE, totalChunks);
        List<Document> batch = chunks.subList(start, end);
        vectorStore.add(batch);  // 每批最多 10 个
    }
}
```

工程价值：

- 将复杂的 API 限制封装在 Service 内部，对上层业务透明。
- 无论文档多大，系统都能自动平稳地完成向量化。
- 避免因超限导致的请求失败。

如何为文档添加元数据？

在 RAG 架构中，元数据不仅是文档的附加信息，更是实现 **多租户隔离、权限控制及精准检索** 的核心手段。我采用的是“写入时注入、检索时过滤”的闭环方案。

核心实现思路：

1. **注入阶段（写入时）**：在文档分块（Chunking）后，将业务维度的唯一标识（如 `kb_id`）统一注入到每个 `Document` 对象的 `metadata` Map 中。这一步保证了每一条向量数据都自带业务标签。
2. **过滤阶段（检索时）**：
   - **语义优先**：首先利用向量索引在大规模数据中快速筛选出语义最相关的候选集。
   - **精确过滤**：随后在候选集中通过 Stream 流进行元数据匹配，确保最终返回的结果集完全符合业务范围（如指定的一组知识库 ID）。
3. **兼容性设计**：考虑到生产环境数据的演进，在过滤逻辑中加入了类型容错处理，同时支持 `Long` 和 `String` 类型，确保了系统的健壮性。

核心代码实现如下：

1. 写入：元数据标注

```
// KnowledgeBaseVectorService.java:55-57
// 为每个 chunk 添加 kb_id 元数据（统一使用 String 类型存储）
chunks.forEach(chunk ->
    chunk.getMetadata().put("kb_id", knowledgeBaseId.toString())
);
```

2. 检索时按 kb_id 过滤：

```
/**
 * 基于多个知识库进行相似度搜索
 */
public List<Document> similaritySearch(String query, List<Long>
knowledgeBaseIds, int topK) {
    // 1. 向量相似度检索：使用 Spring AI 的 VectorStore 进行语义检索
    List<Document> allResults = vectorStore.similaritySearch(query);

    // 2. 元数据过滤：如果指定了知识库ID，只保留匹配的结果
    if (knowledgeBaseIds != null && !knowledgeBaseIds.isEmpty()) {
        allResults = allResults.stream()
            .filter(doc -> {
                Object kbId = doc.getMetadata().get("kb_id");
                if (kbId == null) return false;
                try {
                    Long kbIdLong = kbId instanceof Long
                        ? (Long) kbId
                        : Long.parseLong(kbId.toString());
                    return knowledgeBaseIds.contains(kbIdLong);
                } catch (NumberFormatException e) {
                    return false;
                }
            })
            .collect(Collectors.toList());
    }

    // 3. Top-K 截取：限制返回数量
    return allResults.stream()
        .limit(topK)
        .collect(Collectors.toList());
}
```

通过在检索链条中强制执行 `kb_id` 过滤，从逻辑上实现了不同用户或业务模块间的数据隔离，是实现权限控制的基础。

本项目当前采用后置过滤，优点是 **数据库兼容性强**，不依赖特定向量数据库的复杂语法。

不过，后置过滤仅适用于小规模数据或演示场景，后续分享的 `FilterExpression`（前置过滤）是生产环境更合适的做法。

如果查出来的前 10 条都不符合 kb_id 过滤条件，导致最后返回结果为空怎么办？

在后置过滤（Post-filtering）模式下，我们先做向量检索（Top-K），再用 Java 代码过滤。如果 `kb_id` 匹配的数据刚好排在第 11 名及以后，而你只取了前 10 名，就会导致结果为空或不足。

最直接的办法是将过滤逻辑下沉到向量数据库。在执行向量近似搜索的同时，利用数据库的标量索引（Scalar Index）先剔除不符合 `kb_id` 的记录。

使用 **Spring AI** 提供的 `FilterExpression` 可以优雅地实现这一点：

```
/**
 * 优化后的搜索实现：采用前置过滤解决“结果空洞”问题
 */
```

```java
public List<Document> similaritySearch(String query, List<Long>
knowledgeBaseIds, int topK) {
    // 1. 使用 Builder 构建流式表达式
    FilterExpressionBuilder b = new FilterExpressionBuilder();

    // 2. 动态构建 IN 查询条件
    // 只有当传入了知识库 ID 列表时才进行过滤
    Filter.Expression filterExpression = (knowledgeBaseIds != null &&
!knowledgeBaseIds.isEmpty())
            ? b.in("kb_id",
knowledgeBaseIds.stream().map(Object::toString).toArray()).build()
            : null;

    // 3. 将过滤条件封装进 SearchRequest
    SearchRequest request = SearchRequest.query(query)
            .withTopK(topK)
            .withFilterExpression(filterExpression); // 关键：数据库层面的过滤

    // 4. 执行检索
    // 此时 vectorStore 会在满足 kb_id 条件的数据集中寻找最相似的 topK 条
    return vectorStore.similaritySearch(request);
}
```

为什么前置过滤能解决“空结果”?

这是面试官最想听到的逻辑闭环：

- **后置过滤（Post-Filtering）的问题**： 向量数据库是一个“黑盒”，它先根据向量距离弹出最接近的 10 条数据。如果这 10 条都不属于你的知识库，Java 层面的 `filter` 就会把它们全部剔除，导致最终 **Result = 0**。
- **前置过滤（Pre-Filtering）的优势**： 它告诉向量数据库：“请**只看**那些 `kb_id` 在列表中的数据，并从中给我找最像的 10 条”。只要指定的知识库里有数据，返回的结果就永远不会因为过滤而变少，除非该知识库本身的总数据量少于 `topK`。

如果前置过滤导致索引失效怎么办?

确实存在这种情况。在某些向量数据库中，前置过滤如果通过标量索引筛选掉 99.9% 的数据，可能会导致向量索引（如 HNSW）无法有效工作。

但对于**多租户/多知识库**场景，我们通常会对 `kb_id` 建立**复合索引**。在 pgvector 中，我们可以通过元数据字段建立 Gin 索引或普通的 B-tree 索引。Spring AI 的 `FilterExpression` 屏蔽了底层实现，但在数据库层面，我们会通过执行计划优化，确保先通过标量索引缩小空间，再进行向量计算，从而兼顾准确性和性能。

流式响应与 SSE

☆ 如何实现 AI 回答的流式输出?

在 RAG 系统中，由于大模型生成全文需要较长时间，为了降低用户感知延迟，我采用了基于 **SSE (Server-Sent Events)** 的流式输出方案。这种方案相比 WebSocket 更轻量，且原生支持 HTTP 协议。

流式输出让用户可以实时看到 AI 的回答，而不是等待全部生成完毕，显著提升用户体验。

Spring WebFlux 原生支持 SSE，通过 `MediaType.TEXT_EVENT_STREAM_VALUE` 和 `Flux<ServerSentEvent<T>>` 可以轻松实现流式输出。

基础用法：

```
@GetMapping(value = "/stream", produces = MediaType.TEXT_EVENT_STREAM_VALUE)
public Flux<String> streamData() {
    return Flux.interval(Duration.ofMillis(500))
        .map(seq -> "data: 消息 " + seq + "\n\n");
}
```

- `MediaType.TEXT_EVENT_STREAM_VALUE`：声明响应类型为 SSE 事件流，值为 `text/event-stream`。
- `Flux<String>`：响应式流类型，返回多个字符串事件。
- `Flux.interval()`：每 500 毫秒发射一个递增序列。
- 手动拼接 SSE 格式：`data:` 前缀 + `\n\n` 分隔符。

使用 `ServerSentEvent` 包装：**

```
@GetMapping(value = "/stream", produces = MediaType.TEXT_EVENT_STREAM_VALUE)
public Flux<ServerSentEvent<String>> streamData() {
    return Flux.interval(Duration.ofMillis(500))
        .map(seq -> ServerSentEvent.<String>builder()
            .id(String.valueOf(seq))            // 事件 ID
            .event("custom-event")               // 自定义事件类型
            .data("消息 " + seq)                 // 事件数据
            .retry(3000L)                        // 重连间隔
            .build());
}
```

- `ServerSentEvent<T>`：Spring 提供的 SSE 事件包装类，自动处理 SSE 格式。
- 字段说明：
  - `id()`：设置事件唯一标识，客户端断线重传时可作为断点恢复的依据。
  - `event()`：自定义事件类型，客户端可通过 `addEventListener('custom-event')` 监听。
  - `retry()`：告诉客户端连接断开后等待多久重连（毫秒）。

Spring AI 的 `ChatClient` 提供了流式调用接口**：

```
Flux<String> responseFlux = chatClient.prompt()
    .system(systemPrompt)
    .user(userPrompt)
    .stream()  // 关键：使用 stream() 方法启用流式输出
    .content();
```

流式响应中如何处理错误?

在流式输出场景下，错误处理极具挑战性，因为 HTTP 状态码通常在连接建立时就已经发送（200 OK），一旦流中途断开，无法通过传统的异常处理器返回错误 JSON。我针对这一特性，设计了一套基于 **响应式钩子** 的可靠性方案。

本项目的策略：

1. **保存已接收的部分内容**：即使中途出错，也尽量保存已生成的内容。
2. **前端优雅降级**：当流异常中断时，后端会捕获异常并包装成特定的 SSE 错误信号或友好提示推送到前端，确保前端 UI 能够正确停止加载状态并给予用户反馈。
3. **日志记录**：记录详细错误信息便于排查。

```
.doOnError(e -> {
    // 即使出错也保存已接收的内容
    String content = !fullContent.isEmpty()
        ? fullContent.toString()
        : "【错误】回答生成失败：" + e.getMessage();
    sessionService.completeStreamMessage(messageId, content);
    log.error("RAG 聊天流式错误: sessionId={}", sessionId, e);
});
```

异步处理

☆ 为什么使用 Redis Stream 处理 AI 任务?

AI 调用通常比较耗时（几秒到几十秒），如果同步处理会导致：

- HTTP 请求超时。
- 服务器线程被长时间占用。
- 用户体验差（长时间等待无响应）。

如何实现任务重试机制?

在知识库向量化这种耗时且依赖外部 API（Embedding 服务）的场景下，我设计了一套完整的任务生命周期管理机制。该方案通过 **自动补偿、手动干预、前端静默轮询** 三者结合，构建了可靠的任务闭环。

当任务处理失败时，如果未超过最大重试次数（默认 3 次），消费者会将任务重新发送到 Stream：

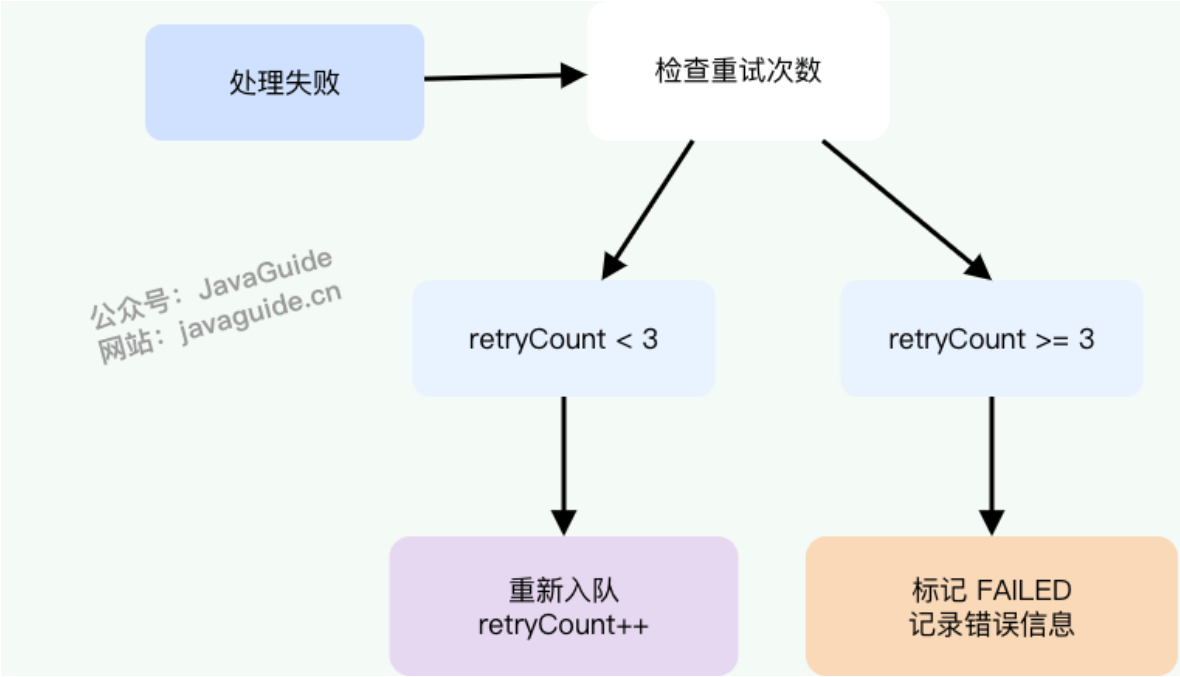

公众号：JavaGuide
网站：javaguide.cn

对于已标记为 FAILED 的任务，提供手动重试 API：

```
// Controller
@PostMapping("/api/knowledgebase/{id}/revectorize")
public Result<Void> revectorize(@PathVariable Long id) {
    uploadService.revectorize(id);
    return Result.success(null);
}

// Service
```

```java
@Transactional
public void revectorize(Long kbId) {
    KnowledgeBaseEntity kb = knowledgeBaseRepository.findById(kbId)
        .orElseThrow(() -> new BusinessException(ErrorCode.NOT_FOUND, "知识库不存在"));

    // 重新下载并解析文件
    String content = parseService.downloadAndParseContent(
        kb.getStorageKey(), kb.getOriginalFilename());

    // 重置状态
    kb.setVectorStatus(VectorStatus.PENDING);
    kb.setVectorError(null);
    knowledgeBaseRepository.save(kb);

    // 发送新任务
    vectorizeStreamProducer.sendVectorizeTask(kbId, content);
}
```

前端通过定时轮询获取任务状态更新：

```java
// KnowledgeBaseManagePage.tsx
useEffect(() => {
  // 只有存在待处理任务时才启动轮询
  const hasPendingItems = knowledgeBases.some(
    kb => kb.vectorStatus === 'PENDING' || kb.vectorStatus === 'PROCESSING'
  );

  if (hasPendingItems && !loading) {
    const timer = setInterval(() => {
      loadDataSilent();  // 静默刷新，不显示 loading 状态
    }, 5000);  // 每 5 秒轮询一次

    return () => clearInterval(timer);
  }
}, [knowledgeBases, loading, loadDataSilent]);
```

优化	说明
条件轮询	仅当存在 PENDING/PROCESSING 任务时才轮询
静默刷新	不显示 loading 状态，避免页面闪烁
合理频率	5 秒间隔，平衡实时性与服务器压力

如果任务量非常大，几千个任务同时在轮询，该如何优化？

引入 WebSocket 或 SSE 进行主动推送；或者在前端采用 指数退避轮询（即任务运行时间越长，轮询频率越低），进一步平衡实时性与服务器负载。

异常处理

如何优雅处理 AI 服务异常？

在 AI 驱动的应用中，大模型 API 的稳定性（如网络波动、限流、配额耗尽）是系统的核心风险点。我通过 **全局异常捕捉、分类精细化处理、以及静态数据降级** 三层防线，确保了系统在高可用方面的韧性。

通过 Spring 的 `@RestControllerAdvice` 实现全局拦截，将复杂的底层网络异常（如 SSL 握手失败、Socket 超时）和 API 业务异常（如 401 密钥失效、429 触发限流）转化为用户可理解的业务错误码。

```java
/**
 * 处理 AI 服务网络异常（SSL握手失败、连接超时等）
 */
@ExceptionHandler(ResourceAccessException.class)
@ResponseStatus(HttpStatus.OK)
public Result<Void> handleResourceAccessException(ResourceAccessException e) {
    Throwable cause = e.getCause();

    // 超时异常
    if (cause instanceof SocketTimeoutException) {
        return Result.error(ErrorCode.AI_SERVICE_TIMEOUT,
            "AI服务响应超时，请稍后重试");
    }

    // SSL握手失败
    if (e.getMessage().contains("handshake")) {
        return Result.error(ErrorCode.AI_SERVICE_UNAVAILABLE,
            "AI服务连接失败（网络不稳定），请检查网络或稍后重试");
    }

    return Result.error(ErrorCode.AI_SERVICE_UNAVAILABLE,
        "AI服务暂时不可用，请稍后重试");
}

/**
 * 处理 AI 服务 API 异常
 */
@ExceptionHandler(RestClientException.class)
@ResponseStatus(HttpStatus.OK)
public Result<Void> handleRestClientException(RestClientException e) {
    String message = e.getMessage();

    // API Key 无效
    if (message.contains("401") || message.contains("Unauthorized")) {
        return Result.error(ErrorCode.AI_API_KEY_INVALID,
            "AI服务密钥无效，请联系管理员");
    }

    // 限流
    if (message.contains("429") || message.contains("Too Many Requests")) {
        return Result.error(ErrorCode.AI_RATE_LIMIT_EXCEEDED,
            "AI服务调用过于频繁，请稍后重试");
    }

    return Result.error(ErrorCode.AI_SERVICE_ERROR,
        "AI服务调用失败，请稍后重试");
}
```

错误码设计（ErrorCode.java）：

错误码	含义
7001	AI_SERVICE_UNAVAILABLE - AI服务不可用
7002	AI_SERVICE_TIMEOUT - AI服务超时
7003	AI_SERVICE_ERROR - AI服务错误
7004	AI_API_KEY_INVALID - API Key无效
7005	AI_RATE_LIMIT_EXCEEDED - 调用频率超限

☆如何实现 AI 调用的降级策略?

当核心 AI 生成链路断开时，系统自动切换至本地静态题库，保证用户基础业务流程不中断。

降级数据不仅仅是简单的提示，而是精心挑选的高频面试题。这种设计将“技术灾难”转化为“可接受的功能降级”，在面试官眼中是极佳的工程素养体现。

本项目的降级策略（`InterviewQuestionService.java`）：

```
public List<InterviewQuestionDTO> generateQuestions(String resumeText, int
questionCount) {
    try {
        // 正常调用 AI
        return chatClient.prompt()
            .system(systemPromptWithFormat)
            .user(userPrompt)
            .call()
            .entity(outputConverter);
    } catch (Exception e) {
        log.error("生成面试问题失败: {}", e.getMessage(), e);
        // 降级：返回预设的默认问题
        return generateDefaultQuestions(questionCount);
    }
}

/**
 * 生成默认问题（备用）
 */
private List<InterviewQuestionDTO> generateDefaultQuestions(int count) {
    String[][] defaultQuestions = {
        {"请介绍一下你在简历中提到的最重要的项目", "PROJECT", "项目经历"},
        {"MySQL的索引有哪些类型？B+树索引的原理是什么？", "MYSQL", "MySQL"},
        {"Redis支持哪些数据结构？各自的使用场景是什么？", "REDIS", "Redis"},
        // ... 更多默认问题
    };

    List<InterviewQuestionDTO> questions = new ArrayList<>();
    for (int i = 0; i < Math.min(count, defaultQuestions.length); i++) {
        questions.add(InterviewQuestionDTO.create(
            i, defaultQuestions[i][0],
            QuestionType.valueOf(defaultQuestions[i][1]),
            defaultQuestions[i][2]
        ));
    }
    return questions;
```

```
}
```

这样即使 AI 服务完全不可用，用户仍然可以进行面试练习。

在生产环境下，我们后续还考虑引入 **Sentinel 或 Resilience4j** 来实现自动**熔断**。当 AI API 的错误率超过 50% 时，系统会自动切断对 AI 的请求，直接进入降级模式，从而避免因大量请求堆积在超时等待上而拖垮整个 Web 服务器。

Spring AI 配置与调优

Spring AI 有哪些重要配置项?

本项目的完整配置（`application.yml`）：

```yaml
spring:
  # Spring AI - 阿里云DashScope (OpenAI兼容模式)
  ai:
    openai:
      # API 端点配置
      base-url: https://dashscope.aliyuncs.com/compatible-mode
      api-key: ${AI_BAILIAN_API_KEY}

      # Chat 模型配置
      chat:
        options:
          model: ${AI_MODEL:qwen-plus}  # 模型名称（可通过环境变量覆盖）
          temperature: 0.2              # 输出随机性（0-1，越高越随机）

      # Embedding 模型配置
      embedding:
        options:
          model: text-embedding-v3      # Embedding 模型

    # 重试配置
    retry:
      max-attempts: 1                   # 不重试，失败立即返回
      on-client-errors: false           # 客户端错误不重试

    # 向量存储配置
    vectorstore:
      pgvector:
        index-type: HNSW                # 索引算法
        distance-type: COSINE_DISTANCE  # 距离度量
        dimensions: 1024                # 向量维度（text-embedding-v3 实际生成的维度）
        initialize-schema: true         # 自动建表
        remove-existing-vector-store-table: false  # 保留现有表和数据
```

配置说明：

配置项	说明	建议值
temperature	控制输出随机性	0.2（偏确定性；需更多多样性时可上调）
max-attempts	重试次数	生产环境建议 2-3 次
index-type	向量索引类型	HNSW（性能最佳）
dimensions	向量维度	与 Embedding 模型匹配

为什么禁用自动重试?

配置中设置了 `max-attempts: 1`，即不重试。原因是：

1. **快速失败**：让用户尽快知道出错了，而不是长时间等待。
2. **避免重复计费**：某些 AI API 按调用次数计费。
3. **业务层控制**：由业务代码决定重试策略（如异步任务中的重试）。

在异步任务场景（Redis Stream 消费者），我们在业务层实现了更精细的重试控制。

如何选择合适的 temperature?

在 LLM 应用开发中，`Temperature` 是调节输出概率分布平滑度的核心超参数。它本质上是在模型输出层的 **Softmax** 函数中引入的一个缩放因子，直接决定了生成内容的随机性与连贯性。

不同业务场景的取值策略：

取值区间	效果描述	推荐业务场景
0.0 - 0.2	**极度严谨**：输出可预测，逻辑严密	JSON 提取、SQL 生成、数据清洗、代码纠错
0.3 - 0.5	**稳健平衡**：在保持逻辑的基础上减少重复感	简历解析、技术文档摘要、代码续写
0.7 - 0.8	**灵动自然**：兼顾专业性与表达的丰富度	面试题生成、通用助手、客服对话等对多样性要求较高的场景
0.9 - 1.2	**天马行空**：鼓励跳跃性思维	创意文案、诗歌创作、头脑风暴

在简历分析并生成面试题的场景中，**如果主要追求出题多样性**，可以考虑将 temperature 调整到 **0.7**，原因包括：

- **多样性需求**：面试不应该只有一套标准模板。我们需要 AI 能够针对同一份简历，从不同的切入点（如项目难点、技术细节、软技能）生成多维度的提问，0.7 能提供这种适度的变通。
- **专业性边界**：如果值过高（如 1.0 以上），模型可能会虚构技术名词或偏离求职者的真实项目背景，导致生成的问题不符合职业面试的严肃性。
- **逻辑连贯性**：面试题需要符合上下文逻辑，0.7 能够在保证问题的业务逻辑合理（不胡说八道）的前提下，让语言表达更像真人面试官。

本项目当前在 `application.yml` 中的默认配置为 `temperature: 0.2`，偏向**结构化输出和结果稳定性**；如需在某些场景（例如仅生成面试题时）提升多样性，可在环境变量或单独的模型配置中上调该值。

高级特性与最佳实践

如何实现多租户的 RAG 系统?

本项目通过 **Metadata 过滤** 实现了简单的多租户隔离:

```
// 存储时标记所属知识库
chunks.forEach(chunk ->
    chunk.getMetadata().put("kb_id", knowledgeBaseId.toString())
);

// 检索时按知识库过滤
List<Document> results = vectorStore.similaritySearch(query).stream()
    .filter(doc -> knowledgeBaseIds.contains(doc.getMetadata().get("kb_id")))
    .collect(Collectors.toList());
```

在向量入库时，为每一个分块（Chunk）强制注入租户标识（如 `tenant_id` 或 `kb_id`）。在检索时，通过数据库索引对该字段进行硬性过滤。

更完善的方案:

如果需要更严格的租户隔离，可以考虑:

1. **Schema 隔离**: 为每个租户创建独立的数据库 Schema（如 PostgreSQL Schema）。
2. **Table 隔离**: 每个租户使用独立的向量表。
3. **Collection 隔离**: 在 Milvus 等专业向量库中创建独立 Collection。

如何处理长文本场景下的 Token 溢出问题?

在模拟面试的评估环节，由于整场面试的对话记录（Question + Answer）往往超过模型的 Context Window 限制，直接提交会导致 API 报错。我设计并实现了 **分批评估 + 二次总结** 架构:

1. **动态分批**: 将面试记录按可配置的批次（如 8 组/批）进行逻辑切分。
2. **阶段评估**: 对每批次独立调用大模型，生成局部维度评分。
3. **二次总结 (Summary Refinement)**: 将各阶段的评估 JSON 作为输入，由模型生成最终的全局面试报告。
4. **容错降级**: 若二次总结失败（如解析报错），系统自动降级为对分批结果进行简单的加权物理合并，确保评估链路的 100% 可靠产出。

☆ 为什么在处理流式对话时推荐使用 Java 21 虚拟线程?

AI 对话（SSE）是典型的 **IO 密集型且高延迟** 场景。

痛点: 传统线程池模式下，一个用户连接会占用一个物理线程。在 AI 生成 Token 的漫长等待中（几秒到几十秒），该线程会被阻塞，导致服务器并发能力受限且资源浪费严重。

解决方案: 全面启用 **Java 21 虚拟线程（Virtual Threads）**。

- **极致吞吐**: 虚拟线程是用户态线程，创建成本极低。当 AI 调用阻塞时，虚拟线程会自动释放载体物理线程，让其去处理其他任务。
- **并发承载**: 在不改变同步编程习惯的前提下，单实例即可支撑万级并发的流式 SSE 会话。
- **本项目应用**: 在 `application.yml` 中开启 `spring.threads.virtual.enabled=true` 即可。

如何优化 RAG 的检索质量?

在本项目中，我针对 RAG 检索的准确性与鲁棒性进行了多维度的深度优化:

1. **查询改写 (Query Rewrite)**：
   用户输入的原始 Query（如 "Java"、"面试"）往往过于简短，缺乏语义检索价值。我引入了 **Query Rewrite** 能力，利用 LLM 结合当前会话上下文将原始 Query 扩展为语义丰富的长句（如 "请总结该候选人的 Java 面试表现及核心考点"），显著提升了向量检索的命中精度。
2. **动态检索参数矩阵 (Top-K/minScore)**：
   不再使用固定的 `Top-K=5`。系统会根据改写后的 Query 长度自动切换检索策略：
   - **短 Query**：采用大召回策略（`Top-K=20`，`minScore=0.18`），确保不漏掉潜在信息。
   - **长 Query**：采用精简策略（`Top-K=8`，`minScore=0.28`），提升上下文的信息密度。
3. **有效命中判定 (Effective Hit Detection)**：
   为了防止模型对弱相关片段进行过度解读（幻觉），我增加了**有效命中判定逻辑**。针对短词 Query，若检索出的片段中未物理包含原始关键词，则视为无效命中，直接触发统一的简洁拒答模板，拦截了 90% 以上的无效生成。
4. **检索过滤前置 (Pre-filtering)**：
   主导将过滤逻辑从“先检索再过滤”升级为“**SearchRequest 级前置过滤**”。通过 `FilterExpression` 在数据库层面完成 `kb_id` 过滤，彻底解决了后置过滤导致的“召回空洞”问题。

进一步优化方向：

1. **混合检索 (Hybrid Search)**：结合向量相似度与传统关键词检索（BM25）。
2. **重排序 (Rerank)**：引入 Reranker 模型对初步召回的片段进行精细评分。
3. **查询改写进阶**：引入 Multi-Query 或 HyDE 等技术。